

SISTEMA DE SUPORTE A DECISÃO

Predição do Valor FIPE de Veículos de Frota

Produto Mínimo Viável — Modelo de Regressão

Filippe Dumont Lana

Matrícula: 202024526

Engenharia de Produção

Professor: André Serrano

Agosto de 2026

1. Resumo executivo

Este trabalho desenvolve um modelo preditivo para estimar o Valor FIPE de veículos de uma frota de locação a partir de suas características cadastrais e comerciais. A base contém 1.083 registros de ativos.

O modelo final — Random Forest com alvo em escala logarítmica — atingiu erro percentual absoluto médio (MAPE) de 3,83% sobre o conjunto de teste, contra 41,78% do baseline ingênuo no mesmo conjunto. Em valores absolutos, o erro médio é de R\$ 4.037 sobre uma frota cujo valor médio é R\$ 69.321.

O achado metodológico central do trabalho, contudo, não é a métrica. Uma auditoria prévia identificou que o par (Modelo, Ano Modelo) determina o Valor FIPE de forma exata em 100% dos casos da base. Manter essas variáveis produziria um modelo de desempenho aparentemente superior, porém inútil na prática — um mecanismo de consulta a tabela incapaz de avaliar qualquer veículo ausente do cadastro. A exclusão dessas variáveis é a decisão de modelagem mais relevante aqui documentada.

2. Definição do problema

2.1 Contexto e relevância

O Valor FIPE é a referência de mercado utilizada para precificar seguros, definir valor residual em contratos de locação e determinar o momento de desmobilização de ativos. Em uma frota superior a mil veículos, dispor de uma estimativa baseada em características gerais permite simular cenários de composição de frota antes da decisão de compra, sem depender da consulta unitária a cada modelo específico.

2.2 Objetivo e hipótese

Construir um modelo de regressão capaz de estimar o Valor FIPE a partir de montadora, categoria do ativo, ano-modelo, cor, grupo de contrato e situação operacional.

A hipótese de trabalho é que essas características gerais contêm informação suficiente para uma estimativa com erro relativo compatível com uso gerencial.

2.3 Critério de sucesso

Definiu-se, antes da modelagem, o critério de MAPE inferior a 10% no conjunto de teste, com desempenho superior ao de um preditor ingênuo baseado na média.

3. Auditoria da base e vazamento de dados

Antes da modelagem, verificou-se se alguma variável disponível entregaria a resposta de forma direta. O teste consistiu em contar, para cada par (Modelo, Ano Modelo), quantos valores distintos de FIPE existiam na base.

Verificação	Resultado
Pares (Modelo, Ano Modelo) distintos	66
Pares com um único Valor FIPE	66
Percentual determinístico	100,0%

O resultado é esperado do ponto de vista do domínio: a tabela FIPE é indexada justamente por modelo e ano. A consequência para a modelagem, porém, é decisiva. Um algoritmo treinado com essas variáveis não

aprende relação alguma — apenas memoriza o mapeamento. O modelo resultante exibiria métricas elevadas e falharia integralmente diante de um veículo cujo modelo não constasse do treino, que é exatamente o caso de uso pretendido.

Decisão: as variáveis Modelo e Código FIPE foram excluídas do conjunto de features. O modelo passa a operar apenas sobre atributos que descrevem o tipo de ativo, não sua identidade.

4. Preparação dos dados

4.1 Anonimização e conformidade com a LGPD

A base original contém 1.082 placas, 1.082 números de chassi, 891 Renavams e 750 nomes de clientes — dados pessoais de terceiros e identificadores de bens específicos. Como o trabalho é destinado a publicação em repositório público, esses campos foram utilizados apenas para verificação de duplicidade — por meio de hash SHA-256 com sal aleatório — e, em seguida, integralmente removidos da base publicada. Optou-se pela remoção, e não pela pseudonimização, porque identificadores de baixa entropia, como placas, são recuperáveis por força bruta quando o algoritmo e o sal são conhecidos.

4.2 Limpeza

Foram identificados e tratados os seguintes problemas de qualidade:

Problema identificado	Tratamento	Registros
Coluna integralmente vazia (Chave Reserva)	Coluna removida	1 coluna
Colunas constantes (variância zero)	Colunas removidas	5 colunas
Linha totalizadora do relatório de origem (R\$ 73.054.389)	Registro removido	1
Valor FIPE igual a zero ou fora de faixa plausível	Registros removidos	34
Dados pessoais identificáveis	Removidos após checagem de duplicidade	4 colunas

A base passou de 1.083 para 1.048 registros, com descarte de 3,2% — proporção baixa que preserva a representatividade do conjunto.

4.3 Engenharia de features

- Idade: anos decorridos desde o ano-modelo. Torna a depreciação diretamente interpretável e evita que o modelo trate o ano como valor nominal arbitrário.
- Categoria: separa automóvel de motocicleta. A frota inclui 98 motocicletas, cujo patamar de preço é aproximadamente quatro vezes inferior. Sem essa marcação, o modelo interpretaria motocicletas como automóveis de baixo valor.
- Agrupamento de montadoras raras: marcas com menos de dez unidades foram consolidadas na categoria OUTRAS, evitando que a codificação one-hot gerasse variáveis com um ou dois registros — fonte de sobreajuste.

5. Análise exploratória




Figura 1 — Distribuição do Valor FIPE, valor mediano por montadora, comparação entre categorias e evolução por ano-modelo.

A distribuição do alvo é fortemente assimétrica à direita: a mediana situa-se em torno de R\$ 65 mil, mas a cauda se estende até R\$ 232 mil. A categoria do ativo é o divisor mais evidente, com motocicletas concentradas em patamar substancialmente inferior. O valor mediano cresce com o ano-modelo, comportamento coerente com a depreciação, apresentando ruído nos anos mais antigos em razão do reduzido número de unidades.

A assimetria observada motivou a aplicação da transformação logarítmica ao alvo. Com ela, o modelo passa a minimizar o erro proporcional em vez do erro absoluto, impedindo que um pequeno conjunto de veículos de alto valor domine o ajuste.

6. Modelagem

6.1 Protocolo experimental

A base foi dividida em 838 registros de treino e 210 de teste. Todas as transformações — codificação de variáveis categóricas e padronização de numéricas — foram encapsuladas em um Pipeline do scikit-learn e ajustadas exclusivamente sobre o treino, de modo a impedir vazamento de estatísticas do conjunto de teste. A seleção de modelos foi conduzida por validação cruzada de cinco dobras sobre o treino; o conjunto de teste foi utilizado uma única vez, na avaliação final.

6.2 Comparação de algoritmos

Modelo	R^2	MAE (R\$)	MAPE (%)
Regressão Linear (log)	0,922	4.156	5,09

Modelo	R ²	MAE (R\$)	MAPE (%)
Ridge (log)	0,913	4.663	5,62
Random Forest (log)	0,899	3.304	3,70
Árvore de Decisão (log)	0,888	3.373	3,64
Baseline (média)	-0,008	17.486	42,87

Tabela 1 — Desempenho em validação cruzada 5-fold sobre o conjunto de treino.

6.3 Escolha do modelo: por que MAPE e não R²

A comparação revela um trade-off que merece explicitação. A Regressão Linear obtém o maior R², enquanto os modelos baseados em árvore obtêm os menores MAE e MAPE. Não há contradição entre os resultados.

O R² é calculado sobre erros elevados ao quadrado e, por isso, é dominado pelos poucos veículos de valor elevado. A Regressão Linear estima melhor esses casos extremos e lidera naquela métrica. Os modelos de árvore, por sua vez, estimam melhor o veículo típico — o automóvel de entrada em torno de R\$ 65 mil, que representa a maior parte da frota.

Para a decisão que o modelo se propõe a apoiar — estimar o valor de ativos em uma frota majoritariamente composta por veículos de entrada — o erro relativo no caso típico é mais relevante que o ajuste nos casos extremos.

Entre a Árvore de Decisão e o Random Forest, a diferença de MAPE (3,64% contra 3,70%) é inferior ao desvio-padrão observado entre as dobras da validação cruzada (0,85 ponto percentual), configurando empate técnico. O Random Forest foi selecionado por ser um conjunto de centenas de árvores, o que reduz a variância das previsões e o risco de sobreajuste em relação à árvore única. A otimização de hiperparâmetros adotou o MAPE como critério.

A busca em grade sobre número de árvores, profundidade máxima e tamanho mínimo de folha resultou em 200 árvores, profundidade máxima de 10 e folha mínima unitária, com MAPE de 3,68% em validação cruzada.

7. Resultados

Métrica	Random Forest (final)	Regressão Linear	Baseline
R^2	0,816	0,860	-0,00
MAE	R\$ 4.037	R\$ 4.987	R\$ 17.372
RMSE	R\$ 13.698	R\$ 11.964	R\$ 31.924
MAPE	3,83%	5,77%	41,78%

Tabela 2 — Desempenho no conjunto de teste (210 registros não vistos).

O modelo final apresenta MAPE de 3,83%, equivalente a um erro médio de R\$ 4.037 sobre uma frota de valor médio R\$ 69.321. O critério de sucesso estabelecido na Seção 2.3 foi atendido com margem, e o baseline ingênuo foi superado em mais de uma ordem de grandeza.




Figura 2 — Valores previstos versus reais e distribuição dos resíduos.

Os resíduos distribuem-se em torno de zero sem padrão sistemático na faixa central de valores. A dispersão aumenta na faixa superior, comportamento coerente com a menor quantidade de veículos premium disponíveis para treino.




Figura 3 — Trade-off entre métricas em validação cruzada. Os modelos de árvore lideram em MAPE (empate técnico entre si); a Regressão Linear, em R^2 .



Figura 4 — Importância relativa das variáveis no modelo final.

7.1 Interpretação das variáveis

A hierarquia de importância aprendida pelo modelo é consistente com o domínio:

- Categoria (motocicleta) é a variável dominante, refletindo a separação de patamar de preço entre as duas classes de ativo da frota.
- Grupo de contrato (Assinatura) aparece em seguida. Cabe registrar que a relação não é causal: a modalidade contratual não determina o valor do veículo. A variável opera como proxy do perfil de ativo alocado àquela modalidade — correlação útil para previsão, mas que não sustenta interpretação causal.
- Montadora e Ano Modelo / Idade completam o quadro, capturando o posicionamento de marca e o efeito da depreciação.

8. Conclusão

O modelo desenvolvido estima o Valor FIPE de veículos de frota com erro percentual médio inferior a 4%, desempenho adequado ao uso gerencial pretendido e obtido com algoritmos de complexidade moderada.

A contribuição metodológica mais relevante do trabalho está na auditoria de vazamento conduzida antes da modelagem. A manutenção das variáveis Modelo e Código FIPE produziria métricas superiores e um modelo sem utilidade prática. A opção por um resultado numericamente menor, porém metodologicamente defensável, é o que confere validade ao modelo apresentado.

8.1 Limitações

- Homogeneidade da frota: predominam veículos Fiat, Citroën e Peugeot dos anos 2023 a 2025. O modelo não deve ser aplicado a marcas ou faixas de valor ausentes da base.
- Recorte estático: os dados constituem uma fotografia única, sem série temporal, o que impede modelar a evolução do valor ao longo do tempo.
- Natureza proxy da variável Grupo: alterações na política comercial da empresa invalidariam a relação observada e exigiriam retreinamento do modelo.
- Sub-representação da cauda superior: o número reduzido de veículos acima de R\$ 150 mil explica a maior dispersão dos resíduos nessa faixa.

8.2 Próximos passos

A incorporação de quilometragem e histórico de manutenção, ausentes nesta base, representa o caminho de maior potencial de ganho, por constituírem os fatores que diferenciam o valor de mercado de dois veículos idênticos em modelo e ano.